

UNIVERSIDAD
ANDRES BELLO

UNIVERSIDAD ANDRÉS BELLO
FACULTAD DE INGENIERÍA
Minería de Datos – TDFI105

Precio de viviendas en Melbourne

Análisis cuantitativo, preparación de datos
y comparación de modelos

Informe de resultados – Evaluación Solemne 1

Andrés Peña, Maximiliano Gallardo, Patricio Frez y Alejandro Martínez

Docente: Eduardo Correa Marchant

Semestre 2026–S2

SANTIAGO – CHILE
Septiembre de 2026

Índice

Introducción 2

1. Diseño de la estrategia metodológica (AE1) 2

2. Formulación de hipótesis verificables (AE1) 4

3. Análisis de datos cuantitativos (AE1) 4

4. Modelo probabilístico (AE1) 7

5. Tratamiento de datos ruidosos y faltantes (AE2) 8

6. Análisis de Componentes Principales – PCA (AE2) 10

7. Preparación de datos para el modelado (AE2) 11

8. Construcción del modelo de regresión (AE2) 12

9. Entrenamiento y evaluación en R (AE3) 13

Conclusiones 16

Referencias 17

Introducción

Se define un caso organizacional simulado para este análisis: una agencia inmobiliaria necesita comparar estimaciones del precio de venta en el mercado metropolitano de Melbourne y justificar qué modelo predictivo utilizar como referencia interna. La dificultad radica en que las viviendas presentan variaciones importantes en sus características estructurales y de ubicación, además de datos incompletos y valores atípicos de gran magnitud. No se atribuye este encargo a una empresa real.

El objetivo es describir el conjunto de datos *Melbourne Housing Snapshot*, contrastar estadísticamente asociaciones entre características estructurales y espaciales y el precio de venta, y evaluar una regresión lineal múltiple completa frente a una regresión reducida mediante selección por AIC. Para la comparación predictiva se consideran principalmente la raíz del error cuadrático medio (RMSE), que penaliza con mayor intensidad los errores grandes, y el error absoluto medio (MAE), que resume la magnitud media del error en las mismas unidades del precio.

1. Diseño de la estrategia metodológica (AE1)

El enfoque metodológico es cuantitativo, observacional y no experimental. La unidad de análisis corresponde a cada registro de venta residencial contenido en el conjunto de datos. El estudio se concentra en cuantificar asociaciones, describir patrones y evaluar capacidad predictiva, sin atribuir relaciones causales.

Pregunta de investigación: ¿En qué medida las características físicas y de localización de las propiedades se relacionan con su precio de venta en el mercado inmobiliario de Melbourne?

Objetivo general: Analizar la relación entre características físicas y de localización de las propiedades y su precio de venta mediante análisis exploratorio, correlación, reducción de dimensionalidad y regresión lineal múltiple.

Tabla 1: Procedencia, alcance y composición del conjunto de datos

Elemento	**Fuente y composición**
Origen	*Melbourne Housing Snapshot* (datos abiertos).
Distribución usada	*Melbourne Housing Snapshot*, cuenta Dansbecker, Kaggle.
Archivo analizado	`melb_data.csv`: 13.580 filas y 21 columnas.
Ámbito	Ventas residenciales en el área metropolitana de Melbourne.
Contenido	Identificadores, características físicas, variables espaciales, ubicación y precio.
Selección de trabajo	`Price` como variable respuesta y ocho predictoras numéricas para el modelado.

Nota. Origen y alcance del conjunto de datos referenciado desde Kaggle (Dansbecker, s. f.).

Variables de trabajo

Tabla 2: Variables seleccionadas, nivel de medición y función en el análisis

Variable	Descripción	Medición	Función
`Price`	Precio de venta de la propiedad	Razón	Respuesta
`Rooms`	Número de habitaciones principales	Razón	Predictora
`Distance`	Distancia respecto del centro de Melbourne (CBD)	Razón	Predictora
`Bathroom`	Número de baños	Razón	Predictora
`Car`	Número de espacios para estacionamiento	Razón	Predictora
`Landsize`	Superficie del terreno	Razón	Predictora
`BuildingArea`	Superficie construida	Razón	Predictora
`YearBuilt`	Año de construcción	Intervalo	Predictora
`Propertycount`	Cantidad de propiedades asociadas al área	Razón	Predictora
`Type`	Tipo de propiedad	Nominal	Exploratoria

Las restantes variables se conservan para diagnóstico o contextualización, pero no forman parte del conjunto inicial de predictores utilizado en PCA y regresión. Las variables de identificación o localización muy específica, como `Address`, no se priorizan para el modelado. `Bedroom2` fue revisada durante la exploración, pero no se incorporó al conjunto final de predictoras para evitar redundancia con `Rooms`.

Técnicas y resguardos éticos: Se aplicarán diagnóstico descriptivo, análisis de distribuciones y valores atípicos, correlaciones no paramétricas, ajuste probabilístico, tratamiento de datos faltantes mediante MICE con PMM, Análisis de Componentes Principales (PCA), estandarización, diagnóstico de multicolinealidad y regresión lineal múltiple (Correa Marchant, 2026a, 2026b).

Como resguardo ético, se preserva el archivo original y se evita utilizar información individual innecesaria, como direcciones exactas, cuando los resultados pueden comunicarse de forma agregada. Toda transformación, exclusión o imputación debe documentarse y justificarse. Las inferencias se restringen al ámbito y período representados por la muestra observada.

2. Formulación de hipótesis verificables (AE1)

Para que el contraste mediante Spearman sea inequívoco, se define como relación principal la asociación entre la superficie construida y el precio de venta.

Hi: Una mayor superficie construida (`BuildingArea`) se asocia con un mayor precio de venta (`Price`) en las propiedades registradas en Melbourne.

Se utiliza el coeficiente de correlación de Spearman (ρ_S) como contraste principal, con un nivel de significancia $\alpha = 0{,}05$:

$$H_0 : \rho_S(\texttt{Price}, \texttt{BuildingArea}) = 0, \qquad H_a : \rho_S(\texttt{Price}, \texttt{BuildingArea}) \neq 0.$$

Criterios explícitos de contrastación: Se rechazará H_0 si el valor p del contraste de Spearman es menor a $0{,}05$. Para respaldar además la dirección propuesta en Hi, el coeficiente deberá ser positivo.

En la regresión lineal múltiple, la significancia global del modelo se evaluará mediante la prueba F, mientras que la significancia individual de cada coeficiente se evaluará mediante sus respectivos valores p. Una asociación estadísticamente significativa no demuestra causalidad.

3. Análisis de datos cuantitativos (AE1)

El diagnóstico inicial registra 13.580 observaciones y 21 variables. En la variable categórica `Type`, predominan las viviendas tipo “h” (House).

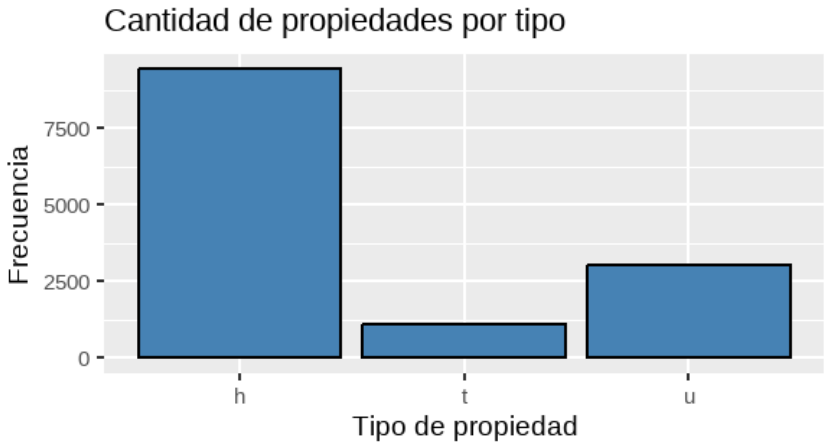


Figura 1: Frecuencia de propiedades según tipo de propiedad

El diagnóstico inicial de las variables numéricas crudas, previo a la imputación, evidencia una alta dispersión en variables asociadas a superficies y tamaño de las

propiedades.

Tabla 3: Posición, dispersión y forma de las variables numéricas analizadas

Variable	Media	Mediana	DE	g_1 (Asimetría)	g_2 (Exceso de curtosis)
`Price` (AUD)	1.075.684	903.000	639.311	2,24	9,87
`Rooms`	2,94	3	0,956	0,376	0,793
`Bedroom2`	2,91	3	0,966	0,774	8,07
`Distance`	10,1	9,2	5,87	1,68	5,26
`Bathroom`	1,53	1	0,692	1,38	3,59
`Car`	1,61	2	0,963	1,37	5,19
`Landsize`	558	440	3.991	95,2	10.177
`BuildingArea`	152	126	541	77,7	6.343
`YearBuilt`	1.965	1.970	37,3	-1,54	21,2
`Propertycount`	7.454	6.555	4.379	1,07	1,22

Normalidad y valores atípicos

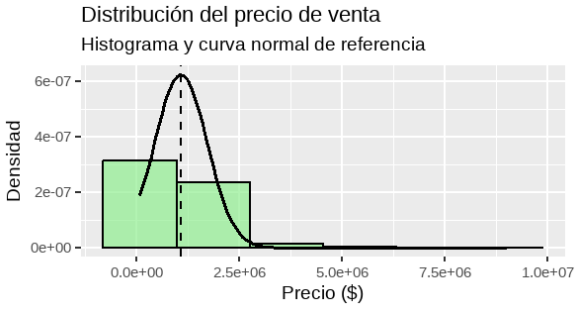


Figura 2: Histograma de `Price` con curva normal de referencia

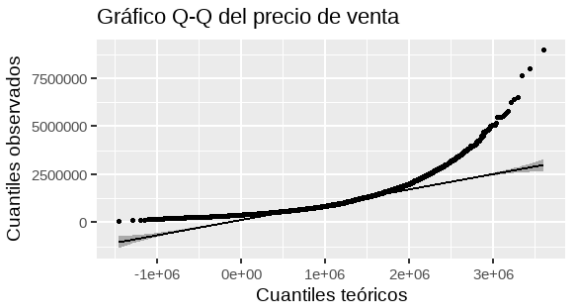


Figura 3: Gráfico Q-Q normal del precio

La asimetría calculada es de $2{,}24$ y la curtosis reportada alcanza $9{,}87$, lo que concuerda con una distribución asimétrica hacia la derecha y con colas marcadas.

Los gráficos muestran una desviación importante respecto de una distribución normal. La prueba de normalidad aplicada en R también rechaza la hipótesis de normalidad al nivel $\alpha = 0{,}05$.

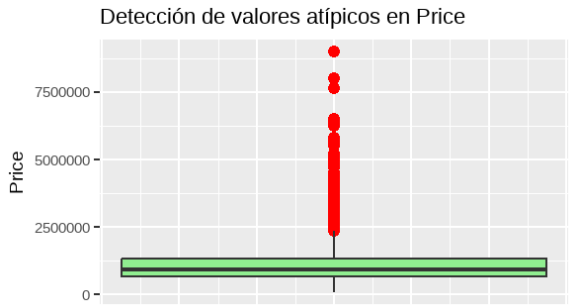


Figura 4: Detección de valores atípicos en `Price`

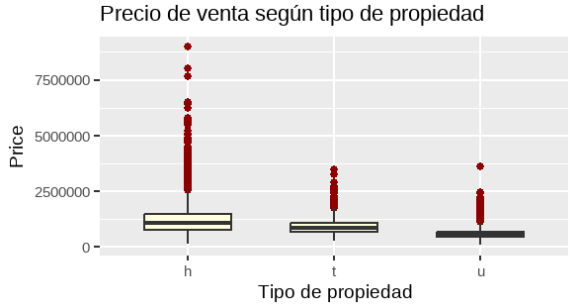


Figura 5: Boxplot comparativo: precio según tipo de propiedad

Los boxplots univariados y bivariados muestran numerosos candidatos a valores atípicos por encima de los límites basados en el rango intercuartílico (IQR), especialmente en las casas de tipo “h”. Se optó por no eliminarlos automáticamente, ya que un valor atípico no implica necesariamente un error de registro y puede corresponder a propiedades de alto valor.

Esta decisión preserva la variabilidad observada y se considera posteriormente al interpretar el desempeño del modelo.

Análisis de correlación

Debido a la fuerte asimetría y a la presencia de valores extremos, se compararon asociaciones mediante Pearson, Spearman y Kendall, priorizando Spearman para el contraste principal por resumir relaciones monótonas mediante rangos.

Tabla 4: Asociaciones bivariadas seleccionadas con el precio

Predictora	Pearson	Spearman	Kendall
`Distance`	-0,163	-0,130	-0,090
`Landsize`	0,038	0,327	0,229
`BuildingArea`	0,091	0,631	0,463
`Car`	0,239	0,288	0,222
`YearBuilt`	-0,324	-0,368	-0,255
`Rooms`	0,497	0,540	0,429
`Bathroom`	0,467	0,427	0,344

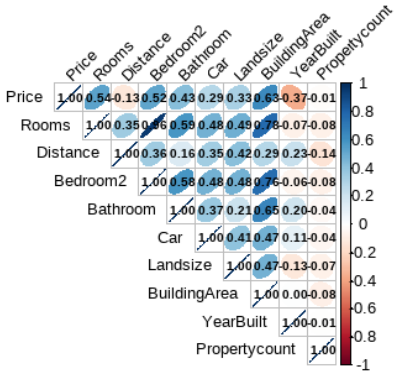


Figura 6: Matriz de correlación de Spearman para predictoras numéricas

El precio presenta una asociación positiva con `BuildingArea` ($\rho_S = 0{,}631$) y `Rooms` ($\rho_S = 0{,}540$).

En particular, el contraste principal entre `BuildingArea` y `Price` entrega un valor $p < 0{,}05$, por lo que se rechaza H_0 y la dirección positiva del coeficiente respalda la hipótesis de investigación.

`Bedroom2` no se incorporó al conjunto final de predictoras para evitar redundancia con `Rooms`.

4. Modelo probabilístico (AE1)

Se ajustaron por máxima verosimilitud una distribución Normal y una Lognormal a la variable respuesta escalada mediante

$$U = \frac{\texttt{Price}}{100{,}000}$$

(Delignette-Muller & Dutang, 2015):

$$U \sim \mathcal{N}(\mu, \sigma^2), \qquad \ln U \sim \mathcal{N}(\mu_{\log}, \sigma^2_{\log}).$$

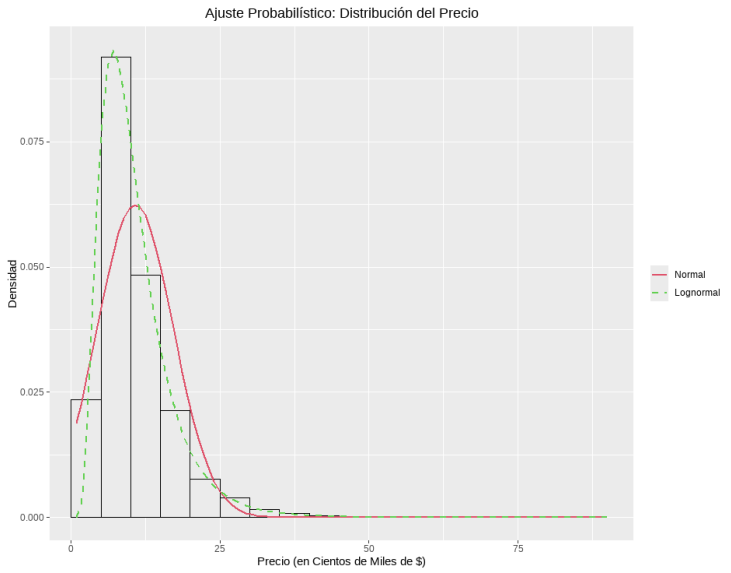


Figura 7: Densidad observada y ajuste de distribuciones Normal y Lognormal

Tabla 5: Bondad de ajuste y criterios de información por modelo probabilístico

Métrica de ajuste	**Normal**	**Lognormal**
Estadístico Kolmogorov–Smirnov	0,1266	0,0267
Estadístico Cramér–von Mises	80,544	1,733
Akaike (AIC)	88.929,16	81.766,25
Bayesiano (BIC)	88.944,19	81.781,28

Interpretación y limitaciones: Entre las dos distribuciones consideradas, la Lognormal presenta un mejor ajuste relativo, pues obtiene menores valores de AIC, BIC y de los estadísticos de discrepancia reportados.

En la distribución Normal, μ representa la media de U y σ su desviación estándar; en la Lognormal, μ_{log} y σ_{log} describen respectivamente la media y desviación estándar de $\ln(U)$, no del precio directamente.

El ajuste es descriptivo y marginal: no incorpora de forma explícita la heterogeneidad espacial ni las demás características de las propiedades, por lo que no demuestra un ajuste perfecto ni reemplaza el modelo predictivo multivariable.

5. Tratamiento de datos ruidosos y faltantes (AE2)

Antes de realizar la imputación se revisaron posibles inconsistencias en los datos originales. Se identificaron seis registros en los que `YearBuilt` es superior al año de venta obtenido desde `Date`. Estos casos se conservaron y se documentaron como inconsistencias potenciales, ya que no se dispone de información suficiente para determinar un valor alternativo de forma fundamentada.

Respecto de los valores faltantes, se observaron NA principalmente en `BuildingArea`, `YearBuilt` y `Car`, además de `CouncilArea`. Esta última no fue imputada debido a que no forma parte del conjunto de predictoras utilizado en los modelos.

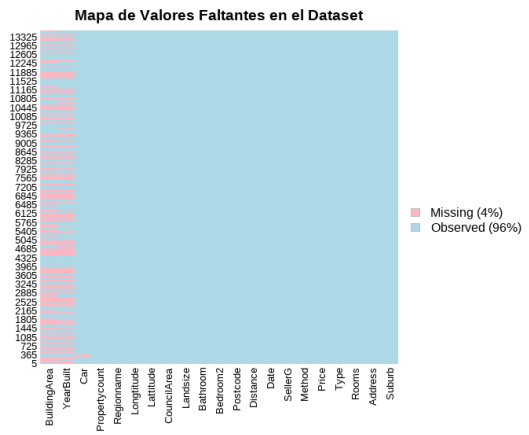


Figura 8: Mapa de valores faltantes antes del tratamiento

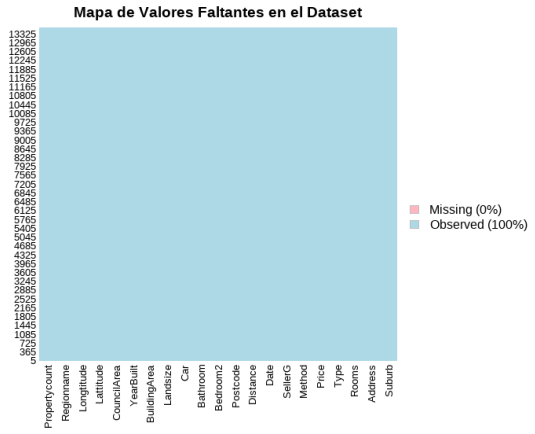


Figura 9: Mapa de valores faltantes después de imputar las predictoras

Tabla 6: Composición de NA en las predictoras imputadas

Predictora	**NA antes**	**NA después**	**Estrategia de tratamiento**
`BuildingArea`	6.450 (47,5 %)	0	Imputación PMM con `mice`
`YearBuilt`	5.375 (39,6 %)	0	Imputación PMM con `mice`
`Car`	62 (0,5 %)	0	Imputación PMM con `mice`

Justificación documentada: La eliminación completa de las filas con datos ausentes habría reducido considerablemente el tamaño de la muestra, especialmente debido a la proporción de faltantes en `BuildingArea` y `YearBuilt`. Por ello se aplicó MICE mediante Emparejamiento de Medias Predictivas (PMM) (van Buuren & Groothuis-Oudshoorn, 2011).

PMM utiliza valores observados de casos donantes plausibles, evitando reemplazar sistemáticamente los datos faltantes por una única media y manteniendo los valores imputados dentro del dominio observado.

La partición entrenamiento–prueba se realizó antes de la imputación. Los modelos internos de MICE se estimaron sin utilizar las observaciones del conjunto de prueba para el aprendizaje de sus parámetros. De esta forma, el conjunto de prueba no aportó información al ajuste de la imputación.

Los valores atípicos identificados previamente no fueron eliminados de forma automática, ya que pueden representar propiedades reales de alto valor y no necesariamente errores de registro.

6. Análisis de Componentes Principales – PCA (AE2)

El PCA se utilizó de forma exploratoria sobre las ocho predictoras numéricas, excluyendo `Price`. El análisis se ajustó únicamente con las observaciones del conjunto de entrenamiento y las variables fueron centradas y estandarizadas.

Su propósito fue resumir la estructura compartida entre las predictoras y evaluar posibles redundancias. Se definió como criterio formal de retención el menor número de componentes necesario para acumular al menos el 80 % de la varianza.

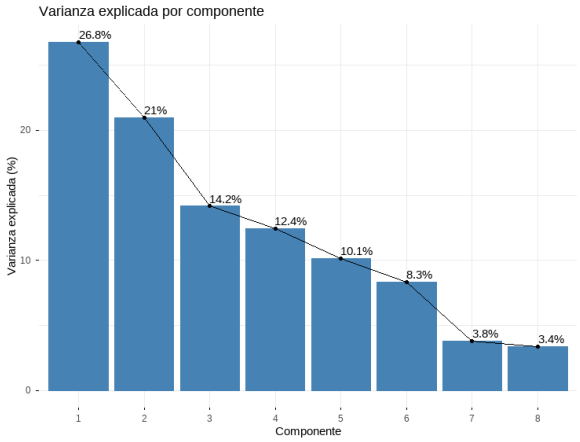


Figura 10: Varianza explicada por componente principal

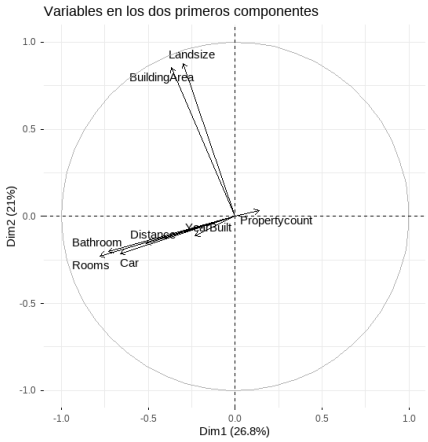


Figura 11: Proyección de variables en los dos primeros componentes

Tabla 7: Autovalor y varianza explicada por los componentes principales retenidos

Componente	PC1	PC2	PC3	PC4	PC5
Autovalor	2,1415	1,6783	1,1327	0,9953	0,8111
Varianza (%)	26,769	20,978	14,159	12,441	10,139
Acumulada (%)	26,77	47,75	61,91	74,35	**84,49**

Interpretación de los componentes

El primer componente principal (PC1) explica el 26,77 % de la variabilidad total y el segundo (PC2) un 20,98 %, acumulando en conjunto un 47,75 %. Por lo tanto, el plano PC1–PC2 permite visualizar una parte importante de la estructura de las predictoras, aunque no la resume por completo.

En la proyección de variables, `Rooms`, `Bathroom` y `Car` presentan direcciones similares, lo que indica patrones de variación relacionados. Asimismo, `Landsize` y `BuildingArea` aparecen próximas, sugiriendo información compartida asociada al tamaño físico de las propiedades. `Propertycount`, en cambio, muestra un comportamiento más diferenciado.

El signo de las cargas en PCA es arbitrario, por lo que la interpretación debe centrarse en la posición relativa de las variables y no en considerar un lado del gráfico como positivo o negativo en términos económicos.

Se requieren cinco componentes para superar el 80 % de varianza acumulada, alcanzando un 84,49 %. Esto indica que existe cierta redundancia entre las ocho predictoras, pero que la información no se concentra únicamente en uno o dos componentes. Por ello, el PCA se utiliza principalmente de forma exploratoria y las regresiones posteriores mantienen las variables originales estandarizadas para conservar una interpretación directa de sus coeficientes.

7. Preparación de datos para el modelado (AE2)

Se definió una partición aleatoria de 80 % para entrenamiento (10.864 observaciones; semilla 105) y 20 % para prueba (2.716 observaciones). Esta partición se realizó antes de la imputación.

Las predictoras con valores faltantes fueron imputadas mediante PMM utilizando modelos estimados sin incorporar las observaciones de prueba en la estimación de sus parámetros.

Posteriormente, las medias y desviaciones estándar utilizadas para la estandarización fueron estimadas exclusivamente con el conjunto de entrenamiento y aplicadas sin reestimación al conjunto de prueba:

$$z_{ij} = \frac{x_{ij} - \overline{x}_{j,\text{ent}}}{s_{j,\text{ent}}}.$$

De esta manera, las etapas de preparación utilizadas para el modelado se definieron a partir del conjunto de entrenamiento. Las ocho predictoras preparadas constituyen las variables de entrada del modelo inicial presentado posteriormente.

Tabla 8: Diagnóstico de multicolinealidad y justificación de uso

Predictora	**Alerta VIF > 5**	**Justificación de inclusión**
`Rooms`	No (1,97)	Espacio principal de la vivienda
`Distance`	No (1,24)	Atributo de ubicación respecto del CBD
`Bathroom`	No (1,71)	Equipamiento interior
`Car`	No (1,27)	Capacidad de estacionamiento
`Landsize`	No (2,12)	Tamaño de la parcela
`BuildingArea`	No (2,15)	Superficie construida
`YearBuilt`	No (1,20)	Año de construcción
`Propertycount`	No (1,01)	Cantidad de propiedades del área

Al verificar el Factor de Inflación de Varianza (VIF), ninguna predictora superó el

umbral de 5 utilizado como señal de alerta. Por lo tanto, no se detecta multicolinealidad severa según este criterio en el conjunto de variables incorporadas al modelo inicial.

Los valores VIF se encuentran aproximadamente entre 1,00 y 2,15. Los mayores valores corresponden a `BuildingArea` y `Landsize`, aunque permanecen ampliamente por debajo del umbral establecido.

Por ello, la posterior eliminación de variables mediante el procedimiento *backward* no responde a un problema de multicolinealidad severa, sino al criterio de información AIC utilizado en la etapa de modelado.

8. Construcción del modelo de regresión (AE2)

La variable dependiente `Price` es numérica continua, por lo que corresponde aplicar regresión lineal múltiple y no un modelo de clasificación.

1. **Regresión completa (inicial):** ajustada por Mínimos Cuadrados Ordinarios (OLS), utilizando simultáneamente las ocho predictoras estandarizadas:

$$\texttt{Price} \sim \texttt{Rooms}+\texttt{Distance}+\texttt{Bathroom}+\texttt{Car}+\texttt{Landsize}+\texttt{BuildingArea}+\texttt{YearBuilt}+\texttt{Propertyco}$$

2. **Regresión reducida (Backward):** parte del modelo completo y aplica selección hacia atrás mediante el Criterio de Información de Akaike (AIC) (R Core Team, s. f.-a).

   El procedimiento retiró `Landsize` y `Propertycount`, por lo que el modelo reducido final conserva seis predictoras:

$$\texttt{Price} \sim \texttt{Rooms} + \texttt{Distance} + \texttt{Bathroom} + \texttt{Car} + \texttt{BuildingArea} + \texttt{YearBuilt}.$$

Secuencia de selección Backward

El procedimiento comenzó con las ocho predictoras del modelo inicial y aplicó selección hacia atrás según el criterio AIC.

El modelo final excluyó `Landsize` y `Propertycount`, conservando seis predictoras. La eliminación de estas variables no responde a multicolinealidad severa, ya que todos los valores VIF fueron inferiores a 5, sino al equilibrio entre ajuste y parsimonia considerado por el AIC.

La selección no se realizó eliminando variables únicamente por su valor p.

9. Entrenamiento y evaluación en R (AE3)

La partición empleada contiene 10.864 observaciones de entrenamiento y 2.716 observaciones de prueba.

El modelo inicial resultó globalmente significativo ($F = 1{,}031$, gl $= 8; 10{,}855$, $p < 2 \times 10^{-16}$), con $R^2 = 0{,}4318$ y R^2 ajustado de $0{,}4314$.

El modelo reducido también resultó globalmente significativo ($F = 1{,}375$, gl $= 6; 10{,}857$, $p < 2 \times 10^{-16}$), con $R^2 = 0{,}4317$ y R^2 ajustado de $0{,}4314$.

Los errores estándar residuales fueron aproximadamente 485.371 AUD y 485.346 AUD para los modelos inicial y reducido, respectivamente.

Coeficientes de los modelos

Tabla 9: Coeficientes de la regresión lineal múltiple inicial

Término	$\hat{\beta}$ **(AUD)**	p	**IC del 95 % (AUD)**
Intercepto	1.073.570	$< 0{,}001$	[1.064.441; 1.082.699]
`Rooms`	222.973	$< 0{,}001$	[210.171; 235.775]
`Distance`	-181.912	$< 0{,}001$	[-192.070; -171.754]
`Bathroom`	193.149	$< 0{,}001$	[181.206; 205.092]
`Car`	60.061	$< 0{,}001$	[49.778; 70.344]
`Landsize`	303	0,9643	[-12.999; 13.605]
`BuildingArea`	19.725	0,0038	[6.353; 33.097]
`YearBuilt`	-128.007	$< 0{,}001$	[-138.004; -118.010]
`Propertycount`	-4.399	0,3471	[-13.571; 4.773]

Tabla 10: Coeficientes de la regresión reducida por AIC

Término	$\hat{\beta}$ **(AUD)**	p	**IC del 95 % (AUD)**
Intercepto	1.073.570	$< 0{,}001$	[1.064.444; 1.082.696]
`Rooms`	223.252	$< 0{,}001$	[210.471; 236.033]
`Distance`	-181.705	$< 0{,}001$	[-191.846; -171.564]
`Bathroom`	193.198	$< 0{,}001$	[181.258; 205.138]
`Car`	60.000	$< 0{,}001$	[49.720; 70.280]
`BuildingArea`	20.003	$< 0{,}001$	[10.818; 29.188]
`YearBuilt`	-128.081	$< 0{,}001$	[-138.071; -118.091]

Nota. Los intervalos de confianza son convencionales y se presentan redondeados. La significancia reportada es nominal; es decir, no se corrige por selección de variables, heterocedasticidad ni por la imputación única realizada.

Interpretación de coeficientes

En el modelo inicial, `Landsize` ($p = 0{,}9643$) y `Propertycount` ($p = 0{,}3471$) no presentan evidencia suficiente de una contribución parcial distinta de cero al nivel $\alpha = 0{,}05$.

En cambio, `Rooms`, `Distance`, `Bathroom`, `Car`, `BuildingArea` y `YearBuilt` presentan valores $p < 0{,}05$. Tras la selección *backward*, se eliminan `Landsize` y `Propertycount`, quedando seis predictoras en el modelo reducido. Debe destacarse que esta selección se realizó mediante AIC y no únicamente según los valores p individuales.

Como las variables predictoras fueron estandarizadas, cada coeficiente representa el cambio esperado en `Price`, expresado en AUD, asociado a un aumento de una desviación estándar en la predictora correspondiente, manteniendo constantes las demás variables.

El intercepto representa el precio esperado cuando todas las predictoras estandarizadas toman el valor cero, es decir, cuando se encuentran en sus medias del conjunto de entrenamiento.

En el modelo inicial, `Rooms` y `Bathroom` presentan los coeficientes positivos de mayor magnitud, con valores aproximados de 222.973 AUD y 193.149 AUD, respectivamente.

Por su parte, `Distance` y `YearBuilt` presentan coeficientes negativos, de aproximadamente -181.912 AUD y -128.007 AUD. Estas asociaciones deben interpretarse de forma condicional al resto de las variables incluidas en el modelo y no como efectos causales.

Un resultado relevante corresponde a `BuildingArea`. En el análisis bivariado mediante Spearman se observó una asociación positiva con `Price` ($\rho_S = 0{,}631$), mientras que en el modelo de regresión inicial también presenta una contribución parcial positiva y estadísticamente significativa ($\hat{\beta} = 19{,}725$ AUD; $p = 0{,}0038$).

Además, `BuildingArea` se mantiene en el modelo reducido. Por lo tanto, los resultados muestran una asociación positiva con el precio tanto en el análisis bivariado como al controlar simultáneamente las demás predictoras del modelo.

Ajuste de los modelos en entrenamiento

Tabla 11: Ajuste de los modelos en el conjunto de entrenamiento

Modelo	AIC	Log-verosimilitud	SSE (AUD^2)	gl residuales	R^2_{ent}
Nulo	321.444	-160.720	$4{,}501 \times 10^{15}$	10.863	0,0000
Inicial	315.319	-157.650	$2{,}557 \times 10^{15}$	10.855	0,4318
Backward	315.316	-157.650	$2{,}557 \times 10^{15}$	10.857	0,4317

En entrenamiento, ambos modelos presentan un ajuste prácticamente equivalente.

El modelo inicial alcanza un R^2 de 0,4318, mientras que el modelo *Backward* alcanza 0,4317. A su vez, el modelo reducido presenta un AIC ligeramente menor (315.316 frente a 315.319) utilizando dos predictoras menos.

Por lo tanto, la reducción del modelo mejora la parsimonia sin producir una pérdida relevante de ajuste en el conjunto de entrenamiento.

Tabla 12: Resumen global de las regresiones en entrenamiento

Modelo	R^2	R^2_{aj}	**Error residual (AUD)**	F	**gl de** F
Inicial	0,4318	0,4314	485.371	1.031	8; 10.855
Backward	0,4317	0,4314	485.346	1.375	6; 10.857

Nota. Ambas regresiones son globalmente significativas, con $p < 2 \times 10^{-16}$.

Métricas y evaluación de desempeño

Tabla 13: Desempeño predictivo en el conjunto de prueba

Modelo	$R^2 \uparrow$	**RMSE (AUD)** $\downarrow$	**MAE (AUD)** $\downarrow$
Regresión inicial (8 var.)	0,419	473.771	334.449
Regresión Backward (6 var.)	0,419	473.832	334.589

Análisis comparativo: Ambos modelos presentan un R^2 de prueba redondeado de 0,419, por lo que su capacidad predictiva observada es prácticamente equivalente.

El modelo inicial obtiene un RMSE de 473.771 AUD y un MAE de 334.449 AUD, mientras que el modelo *Backward* presenta un RMSE de 473.832 AUD y un MAE de 334.589 AUD.

Las diferencias son pequeñas: aproximadamente 61 AUD en RMSE y 140 AUD en MAE.

Si se prioriza estrictamente el error predictivo observado, el modelo inicial presenta un desempeño ligeramente mejor. Sin embargo, el modelo *Backward* utiliza seis predictoras en lugar de ocho, mantiene prácticamente el mismo R^2 y presenta un AIC menor en entrenamiento.

Por lo tanto, el modelo reducido ofrece mayor parsimonia con una pérdida predictiva mínima.

El MAE del modelo inicial indica que sus predicciones se desvían, en magnitud media, aproximadamente 334.449 AUD respecto del precio observado. El RMSE es mayor que el MAE, lo que es consistente con la presencia de algunos errores de predicción de mayor magnitud, ya que esta métrica penaliza más intensamente las desviaciones grandes.

Diagnóstico y alcance de los resultados

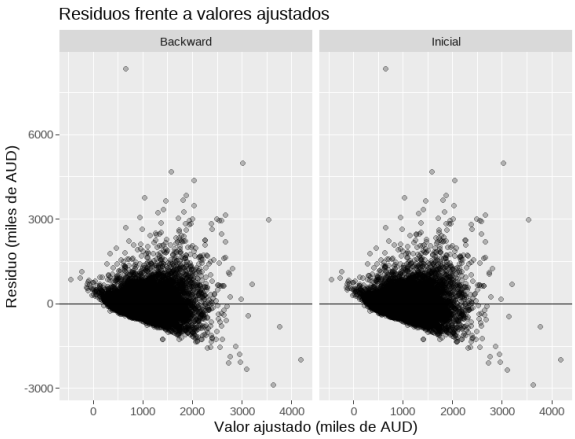


Figura 12: Residuos frente a valores ajustados de los modelos

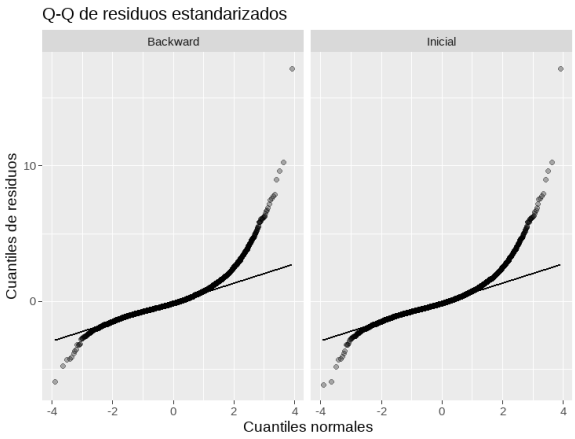


Figura 13: Gráfico Q-Q de los residuos estandarizados

Los dos modelos presentan patrones de residuos muy similares. La dispersión de los residuos no se mantiene completamente uniforme a lo largo de los valores ajustados y se observan algunos residuos de gran magnitud, especialmente para precios estimados más elevados. Este comportamiento sugiere que el supuesto de varianza constante de los errores podría no cumplirse completamente.

El gráfico Q-Q muestra desviaciones claras respecto de la línea de referencia, principalmente en las colas de la distribución. La desviación es especialmente marcada en la cola superior, donde aparecen residuos positivos extremos. Por lo tanto, los residuos no siguen de manera estricta una distribución normal.

Estos gráficos corresponden a diagnósticos visuales y no constituyen, por sí solos, pruebas formales de heterocedasticidad o normalidad. En consecuencia, los coeficientes, intervalos de confianza y valores p convencionales deben interpretarse con cautela.

Además, la evaluación predictiva corresponde a una única partición de entrenamiento y prueba, por lo que las métricas obtenidas describen el desempeño observado en esta división y no garantizan el mismo resultado en otras muestras.

Conclusiones

El contraste principal entre `BuildingArea` y `Price` presenta una asociación positiva de Spearman ($\rho_S = 0{,}631$) y un valor $p < 0{,}05$. Por lo tanto, se rechaza H_0 y los resultados respaldan la dirección planteada en la hipótesis de investigación, sin implicar causalidad.

Además, `BuildingArea` mantiene una contribución parcial positiva y estadísticamente significativa en la regresión múltiple inicial ($\hat{\beta} = 19{,}725$ AUD; $p = 0{,}0038$) y permanece en el modelo reducido.

Entre las dos distribuciones probabilísticas evaluadas, la Lognormal presenta un mejor ajuste relativo que la Normal según los criterios reportados.

El tratamiento mediante MICE con PMM permitió completar las predictoras con valores faltantes sin eliminar una proporción importante de observaciones. La partición entrenamiento–prueba se realizó antes de la imputación y las observaciones de prueba no participaron en la estimación de los modelos utilizados para preparar las predictoras.

El PCA muestra que cinco componentes son necesarios para superar el criterio del 80 % de varianza acumulada, alcanzando un 84,49 %. Debido a que la reducción continúa siendo moderada y se busca conservar la interpretación directa de los coeficientes, las regresiones se ajustaron utilizando las variables originales estandarizadas y no los componentes principales.

La selección *backward* eliminó `Landsize` y `Propertycount`, reduciendo el modelo de ocho a seis predictoras.

En el conjunto de prueba, ambos modelos alcanzan un R^2 aproximado de 0,419. El modelo inicial obtiene errores ligeramente menores (RMSE = 473.771 AUD; MAE = 334.449 AUD), mientras que el modelo reducido presenta valores muy próximos (RMSE = 473.832 AUD; MAE = 334.589 AUD) y un AIC menor en entrenamiento.

Por ello, el modelo inicial ofrece el menor error predictivo observado, mientras que el modelo reducido constituye una alternativa más parsimoniosa con una pérdida predictiva mínima.

Finalmente, los diagnósticos de residuos evidencian observaciones extremas, dispersión no completamente uniforme y desviaciones de normalidad en las colas. Por ello, los resultados deben interpretarse dentro del alcance de esta muestra y de la partición evaluada, considerando además la asimetría de los precios, los valores atípicos y la incertidumbre asociada a la imputación.

Referencias

Correa Marchant, E. (2026a). *Semana 2: Unidad I. El método científico en la ingeniería* [Diapositivas de cátedra]. Universidad Andrés Bello.

Correa Marchant, E. (2026b). *Semana 4: Unidad II. Preparación de la información* [Diapositivas de cátedra]. Universidad Andrés Bello.

Dansbecker. (s. f.). *Melbourne Housing Snapshot* [Conjunto de datos]. Kaggle. Consultado el 12 de septiembre de 2026, desde `https://www.kaggle.com/datasets/`

dansbecker/melbourne-housing-snapshot/data

Delignette-Muller, M. L., & Dutang, C. (2015). fitdistrplus: An R package for fitting distributions. *Journal of Statistical Software, 64*(4), 1–34. https://doi.org/10.18637/jss.v064.i04

R Core Team. (s. f.-a). *Akaike's an information criterion*. R Documentation. Consultado el 11 de septiembre de 2026, desde https://stat.ethz.ch/R-manual/R-devel/library/stats/html/AIC.html

Universidad Andrés Bello. (2026b). *TDFI105: Evaluación Solemne 1. Instrucciones* [Documento de evaluación].

van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software, 45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03